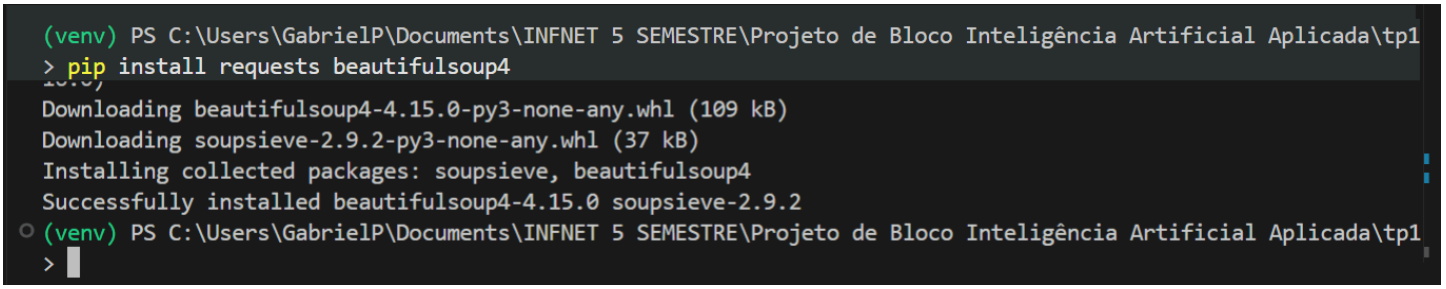
Instituto INFNET
Projeto de Bloco: Inteligência Artificial Aplicada - TP2

Aluno: Gabriel Paulino Pereira
Turma: Ciência de Dados
Entrega: 21/09/2026

Link repositório Github: https://github.com/gabriel-paulino-pereira/infnet-projeto-5bloco-ia-tp2

Extração de Conteúdo da Web para alimentar a aplicação:

- **Instalação das bibliotecas necessárias:**



- **Script de Scraping (src/data/scraping_noticias.py)**

Crio o arquivo scraping_noticias.py dentro da pasta src/data/. O código extrai títulos, links, datas e o texto completo das matérias, salvando um arquivo .csv para dados tabulares e um .txt com todo o texto consolidado para gerar a nuvem de palavras.

scraping_noticias.py

src > data > scraping_noticias.py > ...

```python
            # Agrupo o conteúdo para a composição do corpus textual
            textos_acumulados.append(f"{titulo}. {resumo}".strip())

    # Converto em DataFrame e exporto para CSV
    df_noticias = pd.DataFrame(lista_noticias)
    df_noticias.to_csv(ARQUIVO_CSV, index=False, encoding="utf-8-sig")

    # Escrevo o corpus textual consolidado no arquivo TXT
    with open(ARQUIVO_TXT, "w", encoding="utf-8") as f:
        f.write("\n".join(textos_acumulados))

    print(f"Sucesso: {len(df_noticias)} noticias extraidas e salvas com sucesso.")
else:
    print(f"Falha ao acessar o site. Status code: {resposta.status_code}")
```

Problems Output Debug Console **Terminal** Ports

powershell
Python

```
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Artificial Aplicada\tp1> & "c:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Artificial Aplicada\tp1\venv\Scripts\python.exe" "c:/Users/GabrielP/Documents/INFNET 5 SEMESTRE/Projeto de Bloco Inteligência Artificial Aplicada/tp1/src/data/scraping_noticias.py"

Sucesso: 14 noticias extraidas e salvas com sucesso.
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Artificial Aplicada\tp1>
```

scraping_noticias.py | *corpus_noticias.txt*

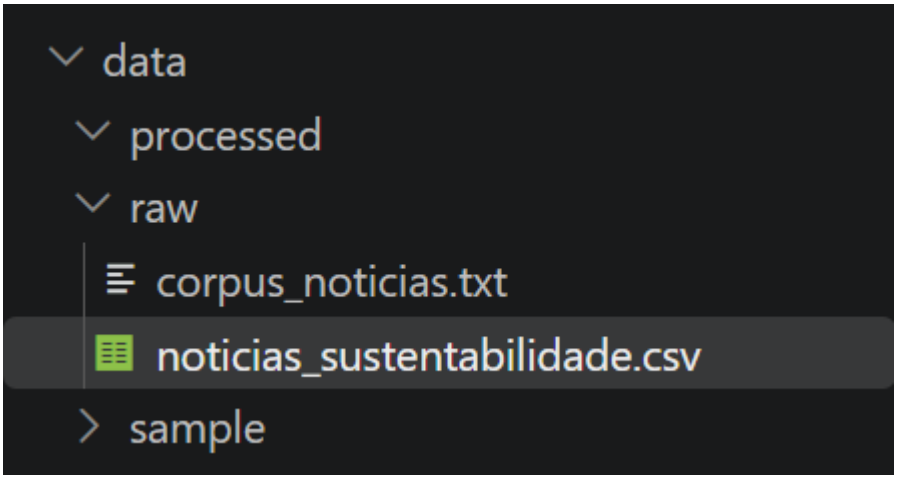
data > raw > corpus_noticias.txt

```
1  Quatro pessoas estão desaparecidas no RS após temporalSegundo a Defesa Civil, 64 municíp
2  Exército brasileiro promove exercício de defesa cibernética.
3  Mega-Sena acumula e pagará R$ 32 milhões na terça; confira dezenas.
4  Cinco pessoas morrem em acidente com ônibus no interior de SP.
5  Mega-Sena sorteia prêmio de R$ 28 milhões neste domingo.
6  Aposentado ou pensionista que votar não precisará fazer Prova de Vida.
7  Após semana em greve, empregados dos Correios têm dissídio na segunda.
8  RJ vai criar 5 mil vagas no sistema penitenciário em três anos.
9  Bolão de Presidente Venceslau (SP) leva R$ 101 milhões na Mega-Sena.
10 CNH vencida entre junho e setembro tem validade extra até dezembro.
11 PF faz ação para combater entrada clandestina de eletrônicos no Brasil.
12 Operação combate infiltração do PCC no transporte público em São Paulo.
13 Inmet prevê final de semana de chuvas nas regiões Sul e Sudeste.
14 Mega-Sena sorteia prêmio acumulado de R$ 102 milhões nesta quinta.
```

scraping_noticias.py | noticias_sustentabilidade.csv

data > raw > noticias_sustentabilidade.csv > data

```
Titulo,Resumo,Link
"Quatro pessoas estão desaparecidas no RS após temporalSegundo a Defesa Civil, 64 munici
Exército brasileiro promove exercício de defesa cibernética,,https://agenciabrasil.ebc.c
Mega-Sena acumula e pagará R$ 32 milhões na terça; confira dezenas,,https://agenciabrasi
Cinco pessoas morrem em acidente com ônibus no interior de SP,,https://agenciabrasil.ebc
Mega-Sena sorteia prêmio de R$ 28 milhões neste domingo,,https://agenciabrasil.ebc.com.b
Aposentado ou pensionista que votar não precisará fazer Prova de Vida,,https://agenciabr
"Após semana em greve, empregados dos Correios têm dissídio na segunda",,https://agencia
RJ vai criar 5 mil vagas no sistema penitenciário em três anos,,https://agenciabrasil.eb
Bolão de Presidente Venceslau (SP) leva R$ 101 milhões na Mega-Sena,,https://agenciabras
CNH vencida entre junho e setembro tem validade extra até dezembro,,https://agenciabrasi
PF faz ação para combater entrada clandestina de eletrônicos no Brasil,,https://agenciab
Operação combate infiltração do PCC no transporte público em São Paulo,,https://agenciab
Inmet prevê final de semana de chuvas nas regiões Sul e Sudeste,,https://agenciabrasil.e
Mega-Sena sorteia prêmio acumulado de R$ 102 milhões nesta quinta,,https://agenciabrasil
```



Cache e Estado de Sessão:

- **Atualização do script principal (src/app.py)**

```
# ============================================================
# 1. IMPLEMENTAÇÃO DE CACHE (@st.cache_data)
# ============================================================
# Utilizo o decorator para carregar os arquivos CSV e TXT do disco apenas uma vez,
# impedindo leituras repetitivas do sistema de arquivos durante a reexecução do
script.

@st.cache_data(show_spinner="Carregando dados raspados do disco...")
def carregar_dados_raspados():
    """
    Realizo a leitura em disco dos dados coletados pelo script de scraping.
    Armazeno em cache para otimizar o tempo de resposta da aplicação.
    """
    caminho_csv = os.path.join("data", "raw", "noticias_sustentabilidade.csv")
    caminho_txt = os.path.join("data", "raw", "corpus_noticias.txt")

    # Verifico a existência prévia dos arquivos
```

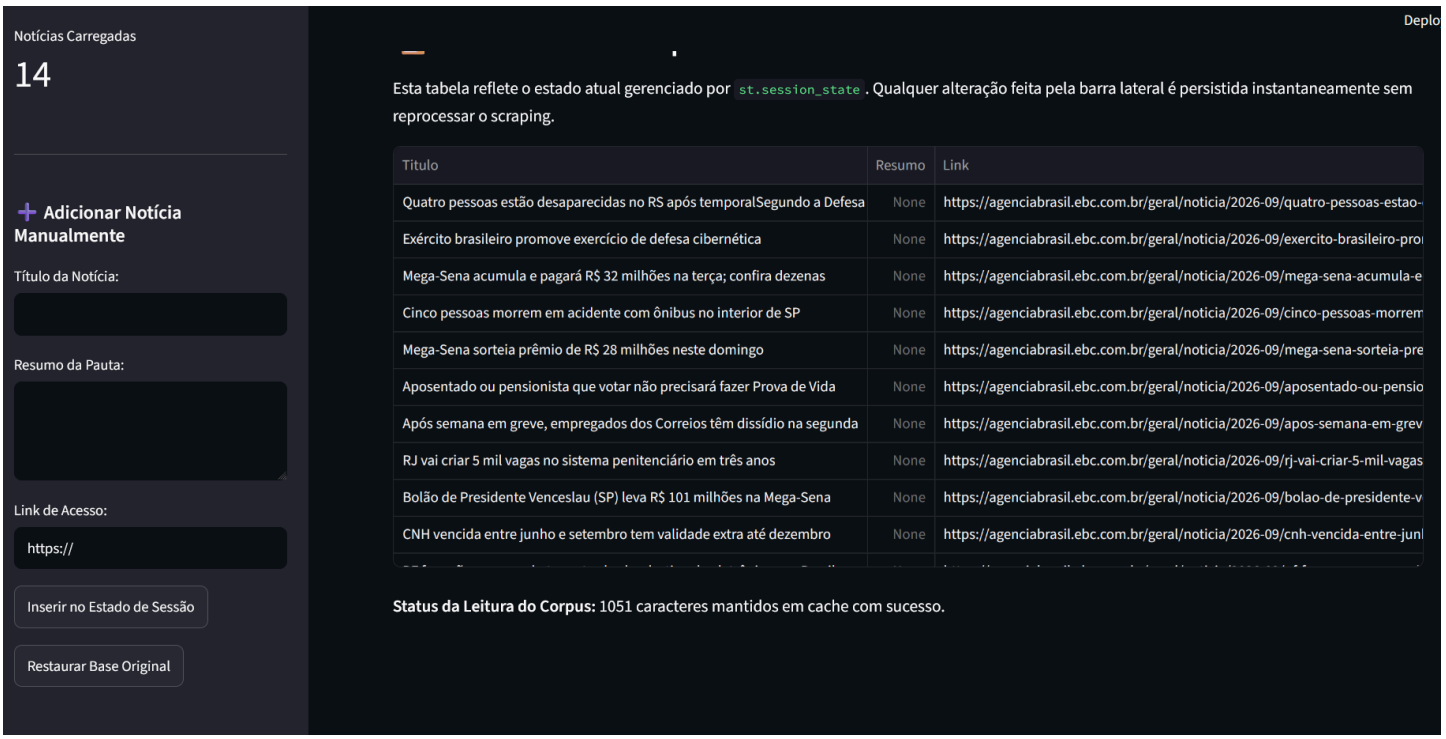
```python
    if os.path.exists(caminho_csv):
        df = pd.read_csv(caminho_csv)
    else:
        df = pd.DataFrame(columns=["Titulo", "Resumo", "Link"])

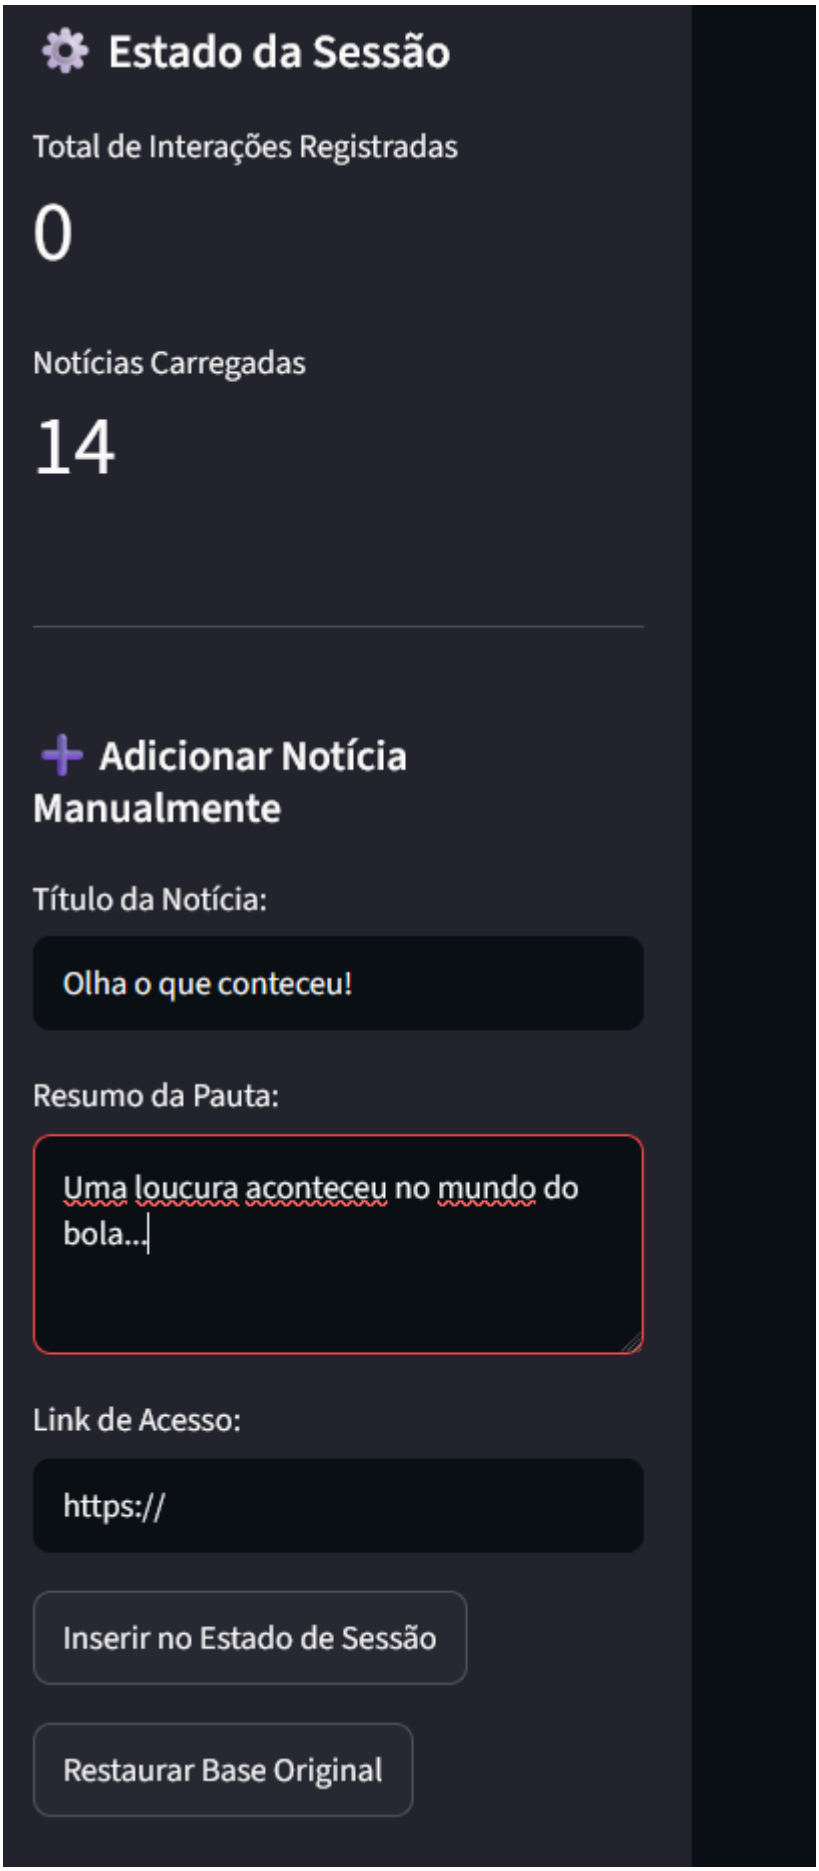
    texto_corpus = ""
    if os.path.exists(caminho_txt):
        with open(caminho_txt, "r", encoding="utf-8") as f:
            texto_corpus = f.read()

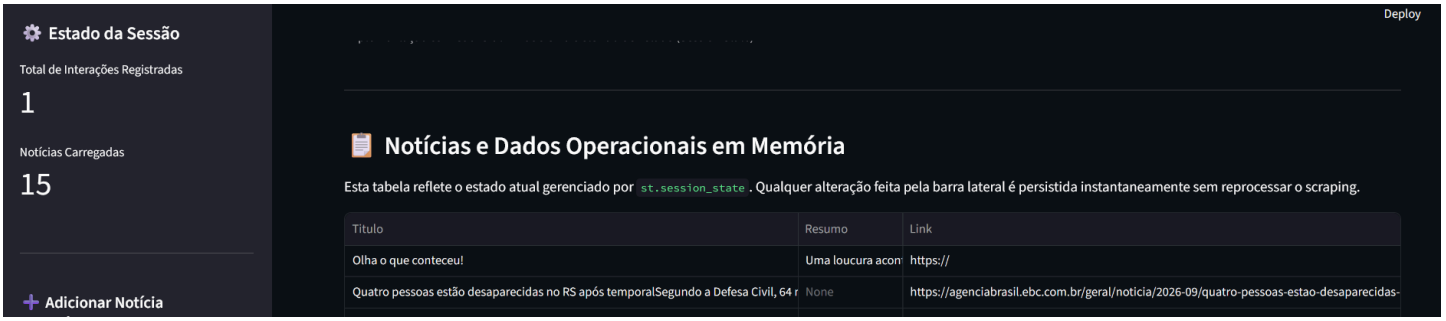
    return df, texto_corpus

# Executo a função cacheada para carregar a base de notícias
df_base, corpus_texto = carregar_dados_raspados()
```






Estado da Sessão
Total de Interações Registradas
0
Notícias Carregadas
14
Adicionar Notícia Manualmente
Título da Notícia:
Olha o que conteceu!
Resumo da Pauta:
Uma loucura aconteceu no mundo do bola...
Link de Acesso:
https://
Inserir no Estado de Sessão
Restaurar Base Original



Serviço de Upload e Download de Arquivos:

Para implementar o serviço de upload e download de arquivos CSV, utilizo os componentes nativos st.file_uploader e st.download_button.

O fluxo funciona da seguinte forma:

Download: Disponibilizo um botão para exportar os dados atualmente carregados na aplicação (incluindo as alterações feitas na sessão) em formato CSV com codificação UTF-8.

Upload: Permito que o usuário suba um arquivo CSV externo contendo novos registros. Faço a validação das colunas esperadas e concateno esses dados diretamente no st.session_state.noticias_ativas, integrando-os imediatamente à interface sem perder o estado.

```
# ============================================================
# 4. ÁREA PRINCIPAL: NAVEGAÇÃO E SERVIÇO DE ARQUIVOS
# ============================================================

aba_dados, aba_arquivos = st.tabs(["📋 Registros em Memória", "📁 Central de Upload / Download"])

with aba_dados:
    st.subheader("Base Operacional de Notícias e Sustentabilidade")
    st.markdown(
        "A tabela abaixo reflete as informações atualmente carregadas em memória no sistema. "
        "Novos dados inseridos manualmente ou via upload CSV são consolidados dinamicamente nesta visualização."
    )
    st.dataframe(
        st.session_state.noticias_ativas,
        use_container_width=True,
        hide_index=True
    )

with aba_arquivos:
    st.subheader("Gerenciamento de Arquivos CSV")
    st.markdown(
```

```
        "Utilize esta seção para exportar a base de dados consolidada ou importar
novos lotes de "
        "registros para enriquecer a aplicação."
    )

    col_upload, col_download = st.columns(2)

    # --- SERVIÇO DE DOWNLOAD ---
    with col_download:
        st.markdown("#### 📤 Exportar Dados")
        st.write("Faça o download de todos os dados ativos no sistema em formato
`.csv`:")

        csv_bytes = converter_df_para_csv(st.session_state.noticias_ativas)

        st.download_button(
            label="Baixar Base de Dados (CSV)",
            data=csv_bytes,
            file_name="base_consolidada_sustentabilidade.csv",
            mime="text/csv",
            key="btn_download_csv"
        )
        st.caption("Arquivo exportado com codificação UTF-8.")

    # --- SERVIÇO DE UPLOAD ---
    with col_upload:
        st.markdown("#### 📥 Importar Novos Dados")
        st.write("Envie um arquivo CSV contendo colunas compatíveis (`Titulo`,
`Resumo`, `Link`):")

        arquivo_enviado = st.file_uploader(
            "Selecione um arquivo CSV para upload",
            type=["csv"],
            key="uploader_csv"
        )

        if arquivo_enviado is not None:
            try:
                # Realizo a leitura do arquivo enviado pelo usuário
                df_upload = pd.read_csv(arquivo_enviado)

                # Valido se as colunas essenciais estão presentes
                colunas_obrigatorias = {"Titulo", "Resumo", "Link"}
                if colunas_obrigatorias.issubset(set(df_upload.columns)):
                    st.write(f"Arquivo lido com sucesso: **{len(df_upload)}** novos
registros encontrados.")

                    if st.button("Integrar Dados ao Sistema"):
```

```
                        # Concateno os novos dados à sessão existente
                        st.session_state.noticias_ativas = pd.concat(
                            [st.session_state.noticias_ativas, df_upload],
                            ignore_index=True
                        ).drop_duplicates(subset=["Titulo"]) # Evito duplicidades
pelo título

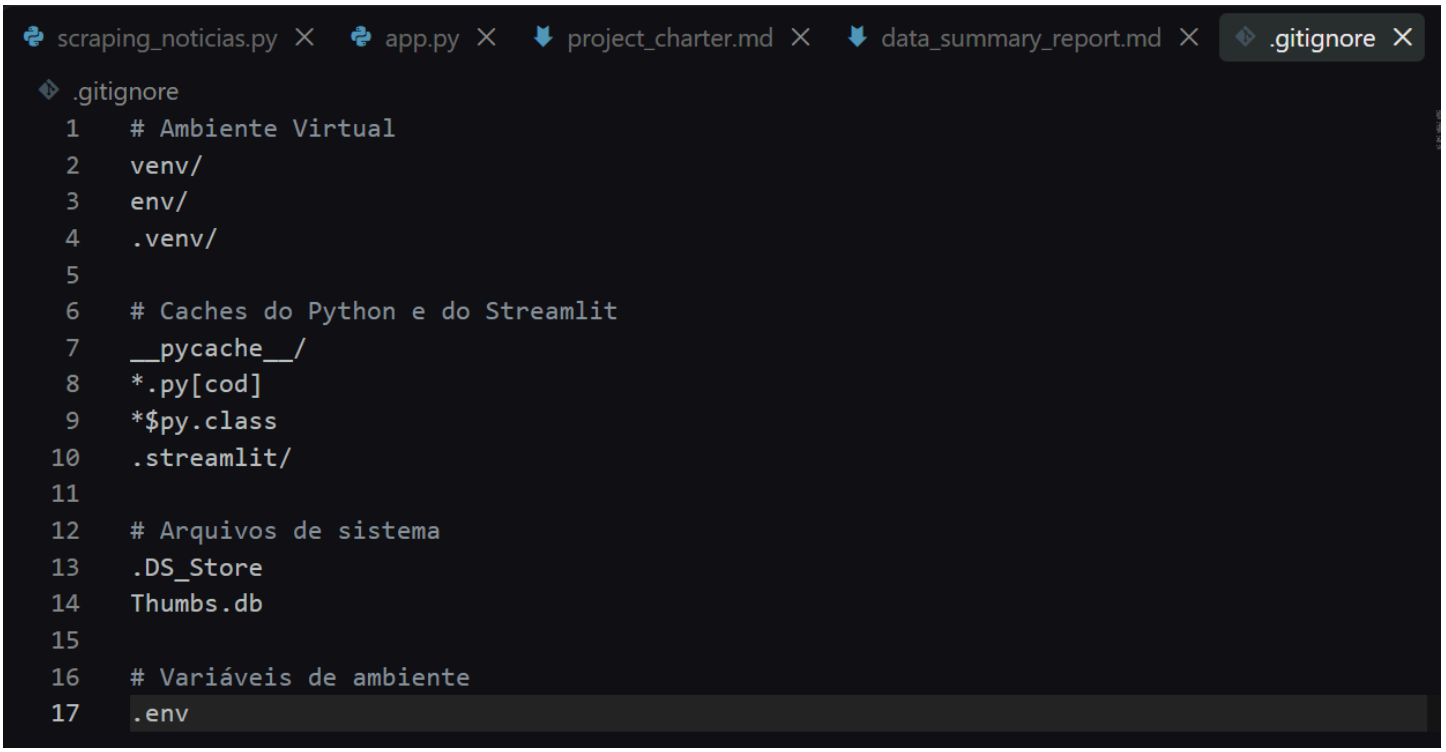
                        st.session_state.total_interacoes += 1
                        st.success("Dados integrados com sucesso à base principal!")
                        st.rerun()
                else:
                    st.error("O arquivo CSV enviado não contém as colunas
necessárias: 'Titulo', 'Resumo', 'Link'.")
            except Exception as e:
                st.error(f"Erro ao processar o arquivo CSV: {e}")
```





Etapa final Git e Github:

- **Configuração do .gitignore**



- **Atualização do requirements.txt**

```
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMES
> pip freeze > requirements.txt
```

- **Inicialização do Repositório Git Local e Commits**

```
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Art
ificial Aplicada\tp1> git init
Initialized empty Git repository in C:/Users/GabrielP/Documents/INFNET 5 SEMESTRE/Projeto
 de Bloco Inteligência Artificial Aplicada/tp1/.git/
```

```
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Art
ificial Aplicada\tp1> git branch -M main
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Art
ificial Aplicada\tp1> git add .
```

```
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Art
ificial Aplicada\tp1> git commit -m "feat: implementa pipeline TP2 com scraping, cache, s
ession state e docs TDSP"
[main (root-commit) 81b5c00] feat: implementa pipeline TP2 com scraping, cache, session s
tate e docs TDSP
 10 files changed, 392 insertions(+)
 create mode 100644 .gitignore
 create mode 100644 README.md
 create mode 100644 data/raw/corpus_noticias.txt
 create mode 100644 data/raw/noticias_sustentabilidade.csv
 create mode 100644 docs/data_summary_report.md
 create mode 100644 docs/gabriel_paulino_pereira_PB_TP1.pdf
 create mode 100644 docs/project_charter.md
 create mode 100644 requirements.txt
 create mode 100644 src/app.py
 create mode 100644 src/data/scraping_noticias.py
```

```
(venv) PS C:\Users\GabrielP\Documents\INFNET 5 SEMESTRE\Projeto de Bloco Inteligência Art
ificial Aplicada\tp1> git push -u origin main
info: please complete authentication in your browser...
Enumerating objects: 17, done.
Counting objects: 100% (17/17), done.
Delta compression using up to 16 threads
Compressing objects: 100% (14/14), done.
Writing objects: 100% (17/17), 861.16 KiB | 17.57 MiB/s, done.
Total 17 (delta 0), reused 0 (delta 0), pack-reused 0 (from 0)
To https://github.com/gabriel-paulino-pereira/infnet-projeto-5bloco-ia-tp2.git
 * [new branch]      main -> main
branch 'main' set up to track 'origin/main'.
```